Санкт-Петербургский государственный университет

Кафедра системного программирования

Группа 25.М71-мм

Исследование надежности LLM-агентов при исполнении бизнес-сценариев

Калашников Матвей Михайлович

Отчёт по производственной практике
в форме «Решение»

Научный руководитель:
доцент кафедры системного программирования, к. ф.-м. н., Гориховский В. И.

Консультант:
разработчик информационных систем, ООО «Озон технологии», Белоголовский И. И.

Санкт-Петербург
2026

Оглавление

Введение **3**

1. Постановка задачи **5**

2. Обзор существующих подходов **6**

2.1. Организация исполнения сценария 6

2.2. Оценка надежности исполнения 7

3. Решение и экспериментальная оценка **8**

3.1. Варианты исполнения сценария 8

3.2. Методика эксперимента 10

3.3. Результаты сравнения 11

Заключение **13**

Список литературы **14**

Введение

Для автоматизации клиентского обслуживания используются боты, которые отвечают на типовые вопросы и выполняют рутинные операции. Это позволяет удешевить обработку обращений и улучшить пользовательский опыт. По результатам исследования Naumen за 2025 год, чат-боты использовались в 67 из 130 опрошенных компаний розничной торговли[1].

Одним из способов создания таких ботов является визуальное программирование. Например, в Microsoft Copilot Studio диалог задается узлами сообщений, вопросов, условий и действий[2]. Такая структура явно задает допустимые переходы, однако при изменении правил или добавлении новых веток сценарий требуется обновлять.

Другой подход предполагает использование LLM-агентов для выполнения сценария. Сценарий задается инструкциями на естественном языке, которые агент интерпретирует с учетом полученных данных, обращаясь к инструментам и ведя диалог с пользователем.

Однако наличие инструкций само по себе не гарантирует правильного выполнения сценария и обязательных действий агентом. Согласно исследованию SOPBench [4] даже наиболее успешный агент с заданными инструкциями не прошел проверку результата и соблюдения процедуры примерно в 24% тестов, а в испытаниях Near-Miss [2] скрытые нарушения последовательности выполнения обнаружены примерно в 8–17% прогонов с вызовами инструментов, изменяющих состояние системы. Авторы Near-Miss использовали τ^2-verified — исправленную версию бенчмарка τ^2-bench [6] для оценки многошагового взаимодействия пользователя, агента и инструментов по заданным правилам.

В компании Ozon используется множество ботов, сценарии которых задаются в среде визуального программирования. Применение LLM-агентов рассматривается как возможность упростить создание и изме-

[1]Naumen: Как ритейл и медицина пересобирают клиентский путь — исследование Naumen. 13.08.2025. URL: https://www.naumen.ru/events/news/7462/ (дата обращения: 11.10.2026).

[2]Microsoft Copilot Studio: Create and edit topics. URL: https://learn.microsoft.com/en-us/microsoft-copilot-studio/authoring-create-edit-topics (дата обращения: 11.10.2026).

нение сценариев, а также улучшить взаимодействие пользователей с ботами.

Таким образом, применение LLM-агентов требует экспериментальной проверки соблюдения сценария. Эта работа направлена на исследование надежности исполнения заданного многошагового сценария при разных способах организации LLM-агента.

1. Постановка задачи

Целью работы является сравнительная оценка надежности исполнения заданного сценария LLM-агентами при разных способах организации их работы.

Для достижения этой цели были поставлены следующие задачи:

1. Проанализировать существующие подходы к описанию сценариев и контролю их исполнения LLM-агентами;
2. Разработать и реализовать варианты исполнения сценария агентом;
3. Разработать методику тестирования и проверки исполнения, подготовить набор тестовых случаев;
4. Провести сравнение реализованных вариантов по правильности итогов и соблюдению обязательных действий, проверить соответствие самоотчета фактическим событиям исполнения.

2. Обзор существующих подходов

Надежность исполнения сценария зависит не только от содержания инструкций, но и от организации работы агента. Ниже рассматриваются способы организации исполнения и подходы к оценке их надежности.

2.1. Организация исполнения сценария

Самый простой подход — передать полное описание сценария одному агенту в системном промпте. Модель выбирает действия на основе этого описания и истории взаимодействия с пользователем и инструментами. При такой организации модель сама определяет текущую позицию в процедуре.

Уменьшить объем инструкций на текущей стадии можно, разделив задачу на последовательные этапы с отдельными промптами. Между этапами передаются полученные результаты. Такой способ организации описан в рекомендациях Anthropic[3]. В настоящей работе сценарий разделен на три последовательные стадии, внутри которых агент самостоятельно выбирает действия.

Управление переходами можно передать внешнему программному компоненту. Он хранит текущий узел и ограничивает допустимые переходы, а модель обрабатывает данные, необходимые для выполнения этого узла. В SOP-Agent [3] используется граф решений, по текущей позиции в котором агент получает инструкции и доступные вызовы. При этом модель интерпретирует полученные данные и определяет, какие условия выполнены и какие ветви следует выбрать. На синтетическом наборе задач клиентского обслуживания с GPT-4 доля правильных последовательностей вызовов составила 99,8% по сравнению с 67,43% у агента с обычной текстовой инструкцией.

Внешний компонент может не только направлять исполнение, но и проверять его ход. PolicyGuide [1] сочетает учет состояния с LLM-верификатором, который проверяет выполненные шаги и формирует

[3]Anthropic: Building effective agents. 19.12.2024. URL: https://www.anthropic.com/engineering/building-effective-agents (дата обращения: 12.10.2026).

рекомендации агенту. На τ^2-bench с GPT-5.4 доля задач, успешно решенных во всех четырех повторах, в среднем по трем областям выросла с 42% без внешней проверки до 62% с PolicyGuide.

Таким образом, рассмотренные подходы различаются по двум признакам: объему инструкций, доступных модели одновременно, и распределению управления переходами. В настоящем исследовании сопоставляются три варианта: единый промпт, последовательные промпты одного агента и программный контроллер с инструкциями текущего шага.

2.2. Оценка надежности исполнения

В бенчмарках τ-bench и τ^2-bench [5, 6] критерии успеха включают конечное состояние среды и необходимые сведения, переданные пользователю. Повторные испытания позволяют оценить устойчивость результата.

Правильный итог не означает соблюдения процедуры. В SOPBench [4] код позволяет проверять конечное состояние, допустимость вызовов инструментов и полноту обязательных проверок. В Near-Miss [2] показано, что агент может достичь правильного итога, пропустив необходимые проверки.

Поэтому в настоящей работе отдельно оцениваются правильность итогового результата, соблюдение процедуры по фактическим действиям и соответствие самоотчета агента событиям исполнения.

3. Решение и экспериментальная оценка

Для сравнения способов организации работы LLM-агента были реализованы три варианта исполнения одного сценария: с единым промптом, с последовательными промптами и с программным контроллером. Выполнение сценария включает получение данных через инструменты, уточняющие вопросы пользователю и выбор конечного результата.

3.1. Варианты исполнения сценария

3.1.1. Единый промпт

В первом варианте весь сценарий описан в одном системном промпте. Он содержит общие правила, шаги и условия перехода, сведения об инструментах, вопросы пользователю и требования к итоговому отчету. В описании шагов указаны разрешенные инструменты и условия их вызова. Агент выбирает действия по инструкциям и истории взаимодействия. По той же истории модель определяет выполненные проверки, полученные ответы и следующий шаг, а также формирует итоговый отчет.

3.1.2. Последовательные промпты

Во втором варианте инструкции разделены на три стадии: начальные проверки, принятие решения в диалоге и завершение сценария. Каждой стадии соответствует свой промпт, при этом все три используются последовательно одним агентом. В промпте каждой стадии описаны ее шаги, разрешенные инструменты и условия их вызова. Между стадиями в структурированном виде передаются полученные данные, результаты проверок и счетчики выполненных действий. Сценарий может завершиться раньше, поэтому не каждый запуск проходит все три стадии.

Разделение уменьшает объем инструкций, с которыми агент работает на текущей стадии. Выбор действий внутри нее по-прежнему выполняет модель.

3.1.3. Контроллер и агент

В третьем варианте управление переходами вынесено в программный контроллер. Он хранит текущий шаг и передает агенту инструкции, накопленные данные и список разрешенных на этом шаге инструментов. Инструкции определяют, какие инструменты и при каких условиях необходимо вызвать. При необходимости агент обращается к инструментам или задает вопрос пользователю. Он интерпретирует данные и возвращает структурированный результат шага с выбранным продолжением. Ответ пользователя поступает контроллеру в составе этого результата и записывается в журнал проверок. Контроллер проверяет структуру ответа и допустимость перехода, после чего фиксирует принятый результат. При отклонении ответа шаг повторяется.

Контроллер программно проверяет порядок переходов и фиксирует пройденные шаги. Это упрощает формирование отчета и точнее отражает путь исполнения, чем в промптовых вариантах.

На рисунке 1 показан обмен инструкциями, данными и результатами между контроллером, агентом, пользователем и инструментами.

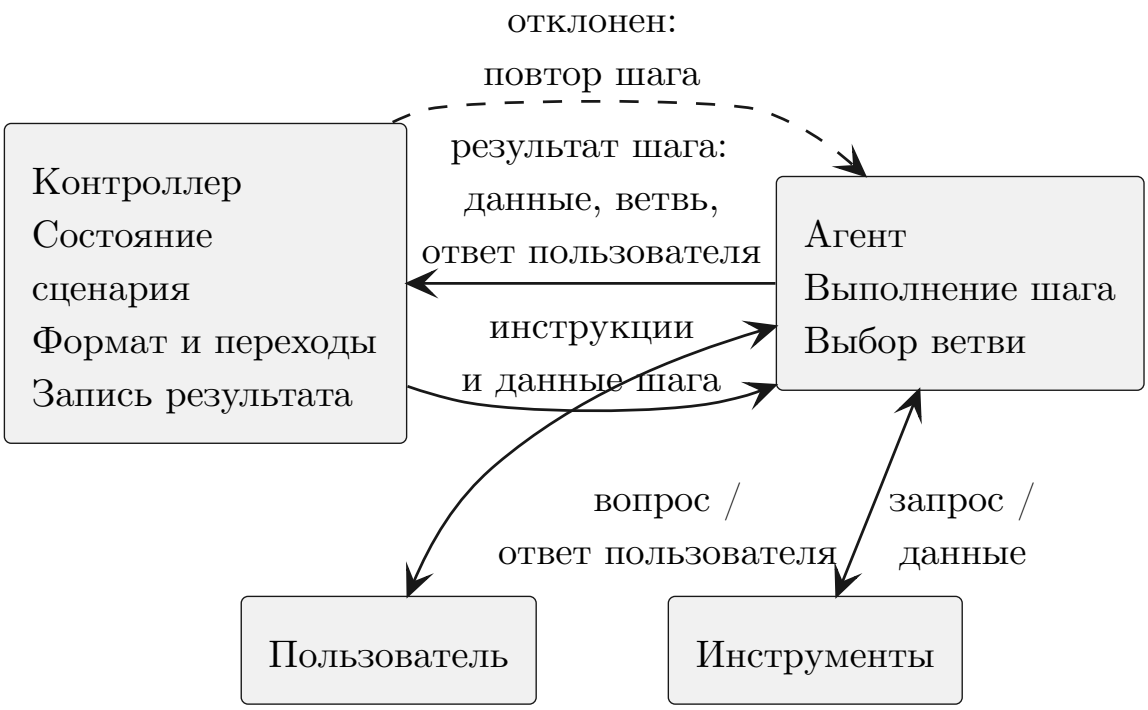


Рис. 1: Взаимодействие контроллера, агента и среды исполнения

3.2. Методика эксперимента

Варианты исполнения тестировались на одном из существующих сценариев. Он представлен 15 шагами и 10 конечными состояниями. Между состояниями 29 переходов. В 11 шагах предусмотрены ветвления, зависящие от полученных данных или ответов пользователя. Агенту доступны четыре инструмента получения данных и отдельный инструмент для вопросов пользователю.

На рисунке 2 показана структура сценария. Цвет узла соответствует основному действию: синий — получение данных, желтый — вопрос пользователю, фиолетовый — проверка или вычисление, зеленый — конечное состояние.

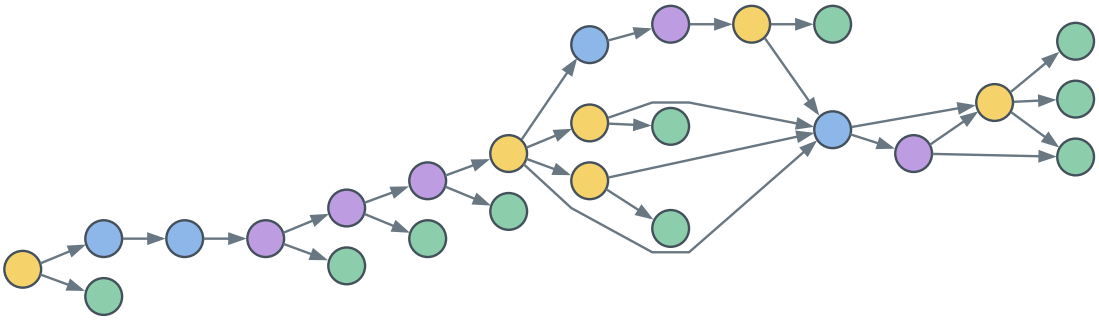


Рис. 2: Структура сценария

Были подготовлены 19 тестовых случаев, охватывающих 10 конечных исходов и 4 типа инструментов получения данных. Распределение тестов по длине эталонного пути представлено в таблице 1.

Таблица 1: Распределение тестов по длине пути

Состояний в пути	2	3	4	5	6	7	8	9	10	11	12	13	14	Всего
Тестовых случаев	2	0	0	2	1	1	0	2	1	5	2	2	1	19

Для каждого теста заданы ожидаемый итог и последовательность действий. Длина эталонного пути составляет от 2 до 14 состояний, включая конечное. Эталонные пути тестов охватывают 28 из 29 переходов сценария (96,6%), а также все 10 конечных состояний.

Каждый тестовый случай запускался 20 раз в независимых сессиях для каждого варианта, что составило 380 запусков. Для всех вариантов использовались одинаковые настройки модели:

- Модель — OpenAI-GPT-OSS-120B.
- Температура — 0,2.
- Максимальная длина ответа — 32 768 токенов.

Правильность исполнения проверялась по сохраненным событиям тестовой среды: сообщениям, показанным вопросам, ответам пользователя и вызовам инструментов с их аргументами и результатами. Отдельно оценивались конечный итог, соблюдение обязательных действий, корректность вызовов, формулировки вопросов, исправление отклоненных ответов и достоверность итогового отчета. Это позволяет отличить правильное завершение от исполнения с пропущенными проверками. Остановка без итогового результата сама по себе не считалась нарушением пути. При расчете доли правильных итогов учитывались все запуски, включая незавершенные.

3.3. Результаты сравнения

Таблица 2: Результаты сравнения

Вариант	Правильный итог	Неверный итог	Нет итогового результата	Нарушения пути	Отклонения отчетности
Единый промпт	370/380 (97,4%)	1	9	16	170
Три последовательных промпта	372/380 (97,9%)	0	8	8	168
Контроллер и агент	380/380 (100%)	0	0	0	1

На выбранных тестах лучший результат по конечным итогам показал вариант с контроллером: все 380 запусков завершились с эталонным результатом. У единого и последовательных промптов доли правильных итогов близки — 97,4% и 97,9% соответственно. Основная часть неуспешных запусков этих вариантов закончилась без конечного результата: девять у единого промпта и восемь у последовательных.

Проверка действий показала, что правильный итог не всегда означал соблюдение сценария. Нарушения пути выявлены в 16 запусках единого промпта и восьми запусках последовательных промптов. У контроллера таких нарушений не обнаружено. В первых двух вариантах встречались пропуски обязательных вызовов инструментов, хотя конечный результат совпадал с эталонным. Единственный неверный итог у единого промпта был связан с использованием ответа на один вопрос как ответа на другой, который агент не задал. Без получения нового ответа агент выбрал дальнейшую ветвь и завершил сценарий с неверным результатом. При последовательных промптах также наблюдались отклонения от заданного порядка выполнения: преждевременные переходы между стадиями и повторные вопросы пользователю.

В варианте с контроллером результат шага проверялся до перехода к следующему. В двух запусках некорректный промежуточный ответ был отклонен, после чего шаг выполнился повторно и сценарий завершился правильно. В этих случаях проверка позволила исправить ошибку до продолжения исполнения. Это показывает практическую пользу контроля промежуточных результатов, которую нельзя увидеть только по конечным итогам.

В 170 из 380 запусков единого промпта (44,7%) отчет содержал неверные сведения о действиях или источниках данных. При последовательных промптах также встречались записи о выполнении шага без обязательного вызова инструмента. Контроллер фиксирует принятые шаги и переходы в журнале, что позволяет проследить ход исполнения независимо от отчета модели. Однако в одном запуске с правильным итогом отсутствовала запись ответа пользователя, а счетчик вопросов показывал два вместо трех.

Заключение

В рамках работы были достигнуты следующие результаты.

- Проведен анализ подходов к описанию сценариев и контролю их исполнения LLM-агентами.
- Разработаны и реализованы три варианта исполнения сценария: с единым промптом, последовательными промптами и программным контроллером.
- Разработана методика тестирования и проверки исполнения. Подготовлены 19 тестовых случаев.
- Проведено сравнение вариантов по корректности итогов и пути исполнения.

Код реализации и исходные материалы экспериментов относятся к внутреннему проекту компании и не могут быть опубликованы.

Список литературы

[1] Kang Seongjae, Yu Taehyung, Hwang Sung Ju. PolicyGuide: From Guarding One Action to Guiding the Whole Workflow for Policy-Compliant LLM Agents. — arXiv. — 2026. — 2608.19861.

[2] Rabinovich Ella, Boaz David, Zwerdling Naama, Anaby-Tavor Ateret. Near-Miss: Latent Policy Failure Detection in Agentic Workflows. — arXiv. — 2026. — 2603.29665.

[3] Ye Anbang, Ma Qianran, Chen Jia et al. SOP-Agent: Empower General Purpose AI Agent with Domain-Specific SOPs. — arXiv. — 2025. — 2501.09316.

[4] Li Zekun, Huang Shinda, Wang Jiangtian et al. SOPBench: Evaluating Language Agents at Following Standard Operating Procedures and Constraints. — arXiv. — 2025. — 2503.08669.

[5] Yao Shunyu, Shinn Noah, Razavi Pedram, Narasimhan Karthik. τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains. — arXiv. — 2024. — 2406.12045.

[6] Barres Victor, Dong Honghua, Ray Soham et al. τ^2-Bench: Evaluating Conversational Agents in a Dual-Control Environment. — arXiv. — 2025. — 2506.07982.