Санкт-Петербургский государственный университет

Кафедра системного программирования

Шаламов Роман Александрович

Автоматическое обнаружение и интеграция новостей в систему принятия решений на финансовом рынке: методика и сбор датасета

Отчет по учебной (проектно-технологической) практике

Научный руководитель:
к. ф.-м. н., доцент кафедры информатики СПбГУ Григорьев Д. А.

Санкт-Петербург
2022

Оглавление

Введение **3**

1. Цель и задачи **4**

2. Обзор существующих работ **5**

3. Подготовка датасета **8**

4. Архитектура системы и стадии разработки **11**

4.1. Стадии разработки 13

4.2. Библиотеки для сбора новостей 13

5. Результаты **15**

Список литературы **16**

Введение

В современном мире финансовые рынки получили очень широкое распространение. Сегодня любой может покупать или продавать акции, действуя таким образом как финансовый инвестор, используя определенные разработанные для этого информационные технологии на базе сети Интернет.

Сами по себе финансовые рынки управляются информацией. Одним из важнейших источников этой информации являются новости, передаваемые множеством информационных агентств по разным каналам. Поскольку финансовые рынки чрезвычайно чувствительны к новостям[8], аналитикам необходимо постоянно отслеживать, какие финансовые события важны и могут повлиять на их торговые стратегии.

Однако в Интернете ежедневно публикуются тысячи новостей из различных источников и с разным содержанием, и их ручное отслеживание становится очень трудоемкой задачей, особенно в режиме реального времени. Все это формирует потребность в автоматизации обработки информации до такой степени, когда инвестиционные решения, в которых важную роль играет фактор новостей, могут быть основаны на автоматически сгенерированной рекомендации, учитывающей значительную часть новостных сообщений из разных источников и относящихся к определенному финансовому активу.

Для решения этой задачи необходимо реализовать автоматическую систему, которая на основе новостных потоков из различных источников сможет формировать торговые стратегии, извлекая из новостей важные признаки, относящиеся к поведению цены на тот или иной актив.

1. Цель и задачи

Целью данной работы является создание первичного эталонного набора данных новостей из финансовых новостных источников и проектирование приложения, которое будет в автоматическом режиме дополнять этот набор данных, а также формировать конечные торговые рекомендации на их основе. Для достижения данной цели были поставлены следующие задачи:

- Поиск и обзор существующих решений по формированию финансовых рекомендаций на основе новостей.
- Формирование первичного набора данных, пригодных для анализа.
- Описание архитектуры приложения для:
  - Постоянного пополнения базы данных релевантными новостями, связанными с тем или иным финансовым активом.
  - Извлечения всех признаков из каждой новости и идентификация наиболее важных для дальнейшего анализа.
  - Интеграции отобранных новостных признаков в систему принятия финансового решения и формировании торговой рекомендации на её основе.
  - Взаимодействия с пользователем в контексте просмотра новостных сообщений или готовых торговых рекомендаций.

2. Обзор существующих работ

Проблема сопоставления большого количества новостей с поведением финансового рынка исследуется с конца прошлого века. За это время было предложено множество фреймворков с разными подходами, общая проблема для всех них – недостаточность автоматизации или практической реализации и, как следствие, трудоемкость работы для реальных конечных пользователей.

Одним из первых подходов к поиску релевантной информации из неструктурированного текста является онтологический подход. Так, в [3] описывается система полуавтоматического заполнения онтологий из неструктурированного текста, которая основана на контролируемом обучении. Система идентифицирует события с помощью технологий извлечения информации и машинного обучения и дополняет созданную вручную онтологию понятий. Данная работа не связана с финансовыми рынками, однако является одной из первых в контексте данного подхода к извлечению информации.

В работе [1] представлено веб-приложение, основанное на OWL (англ. Web Ontology Language), которое позволяет извлекать из RSS-каналов релевантные новости, касающиеся компаний, которые представлены в индексе NASDAQ-100. Целью приложения является отобразить агрегированное представление новостей, разделенных на 4 категории по разным темам. В то же время система, представленная в этой работе, может оценивать эти новости на основе их релевантности по 3 возможным эффектам: отрицательный, нейтральный и положительный.

В более современной работе [6] авторы предлагают лексико-семантические шаблоны, которые в свою очередь используют готовые финансовые онтологии, тем самым усиливая обычные лексико-синтаксические шаблоны для более точного выделения событий из текста. Пользователь данной системы должен быть хорошо знаком с финансовой областью, для него разработан интерфейс управления онтологиями, в котором он может описывать интересующие его события. На основе этих событий система выделяет релевантные новости из нескольких источников

и далее пользователь решает, как выделенная новость может повлиять на онтологию, например, обновив её. Стоит отметить, что данную систему протестировали на источниках, не связанных с финансами и она продемонстрировала определенные успехи в выделении релевантных событий.

Основным недостатком работ, основанных на онтологическом подходе является само создание баз знаний, т.к. они далеко не всегда существуют и это требует больших затрат.

Более современным подходом к формированию рекомандаций является коллаборативная фильтрация (англ. CF — Collaborative filtering)[7], основанная на поведении пользователя на странице (нажатиях, просмотрах и т.п.) Однако эти методы слабо применимы в системах рекомендаций новостей, ориентированных на конкретные задачи, в частности, в фиинансовой индустрии, так как рекомендовать похожие события может быть опасно из-за редкости интересных бизнес-событий (таких как банкротство или поглощение одной компании другой).

Самые современные работы используют NLP и машинное обучение для извлечения релевантности новостей. Так, авторы [2] описывают проект, который находится в разработке в компании S&P Global Ratings. Данный проект представляет из себя полноценную систему для поиска, кластеризации, и ранжирования новостных событий для финансовых аналитиков на рынке долгового капитала. Проект представляет из себя конвейер, основанный на системе подписок, где каждая подписка — некая сущность, которая может быть темой, названием компании, местоположением и т.д. Аналитики создают и редактируют данные подписки, ограничивая таким образом интересующую их информацию. В рамках каждой подписки все поступающие из заранее обозначенных ресурсов новости проходят ряд этапов: предобработку, устранение дубликатов, выявление признаков релевантности и ранжирование. Уже обработанные новости сохраняются в базу данных, с которой пользователь работает через веб-интерфейс. С точки зрения крупной масштабируемой рекомендательной финансово-направленной системы данная работа является очень хорошим примером, однако в

ней достаточно мало технических деталей, что может быть связано с её разработкой в рамках крупной финансовой компании в данный момент.

3. Подготовка датасета

Для первичного анализа новостных статей на предмет извлечения из них релевантной информации для последующего включения в торговую стратегию необходимо подготовить соответствующий набор данных. В качестве источника фундаментального анализа новостей был взят тематический сайт InstaForex[5].

Для сбора данных был выбран раздел с фундаментальным анализом валютных пар, в котором различные аналитики публикуют свои торговые рекомендации и прогнозы в зависимости от той или иной новости. Поскольку сайт не предоставляет API для чтения своих данных, был разработан скрипт, который "листал" данный раздел до самых старых новостей, параллельно записывая информацию о каждой в Excel-файл.

Из всего потока новостей выделялись те, которые содержали в заголовке название валютной пары. Поиск выполнялся для статей на английском языке, однако, для каждой статьи проводилась попытка поиска её аналога на русском путем замены соответствующих символов в url-адресе. Если такая статья существовала, информация о ней так же попадала в конечный набор данных. Данные собирались для 16 наиболее популярных валютных пар по следующим полям:

- **Currency** — название валютной пары.
- **Author** — имя аналитика InstaForex.
- **Author ID** — уникальный идентификатор аналитика InstaForex, формируется в готовом наборе данных.
- **Publication Date (RU)** — дата публикации статьи на русском языке.
- **Publication Time (RU)** — время публикации статьи на русском языке.
- **DateTime (RU)** — дата и время публикации статьи на русском языке в формате ггггммддччмм.

- **Link (RU)** — ссылка на новость на русском языке.
- **Title (RU)** — заголовок новости на русском языке.
- **Text (RU)** — текст новости на русском языке.
- **Recommendations (RU)** — торговая рекомендация аналитика на русском языке. На страницах новостей из данного раздела присутствовал специальный абзац для этого.
- **Publication Date (EN)** — дата публикации статьи на английском языке.
- **Publication Time (EN)** — время публикации статьи на английском языке.
- **DateTime (EN)** — дата и время публикации статьи на английском языке в формате ггггммддччмм.
- **Link (EN)** — ссылка на новость на английском языке.
- **Title (EN)** — заголовок новости на английском языке.
- **Text (EN)** — текст новости на английском языке.
- **Recommendations (EN)** — торговая рекомендация аналитика на английском языке.

Поскольку основной темой изучения является влияние новостных событий на финансовые рынки, к данным полям необходимо было добавить информацию о значениях валютных пар на момент выхода каждой новости. Для этого было опробовано несколько источников, самым полным из которых является HistData.com[4]. С него в ручном режиме были собраны данные о стоимости закрытия (англ. — closing value) валютных пар на каждую доступную минуту с 2000 по 2021 год.

Далее, эта информация была сопоставлена с имеющимися строками в датасете и добавлена следующими полями:

- **Nearest Closing Time** — ближайшее время закрытия валютной пары. Поскольку бывали исключения в сопоставлении даты новости и даты закрытия валютной пары, для таких случаев бралось ближайшее следующее значение цены.

- **Closing Value** — цена закрытия валютной пары.

После сбора всей доступной информации идет этап её обработки — удаление дубликатов, неконсистентных данных. Большинство операций проводилось с использованием написанных на языке Python программ, однако финальная обработка включала ручное исправление найденных ошибок.

Итоговый набор данных состоит из 3590 строк с текстами новостей и значениями соответствующих им цен закрытия валютных пар. Подготовленный набор данных использовался в работе [13].

4. Архитектура системы и стадии разработки

Общая архитектура системы представлена на Рис. 1:

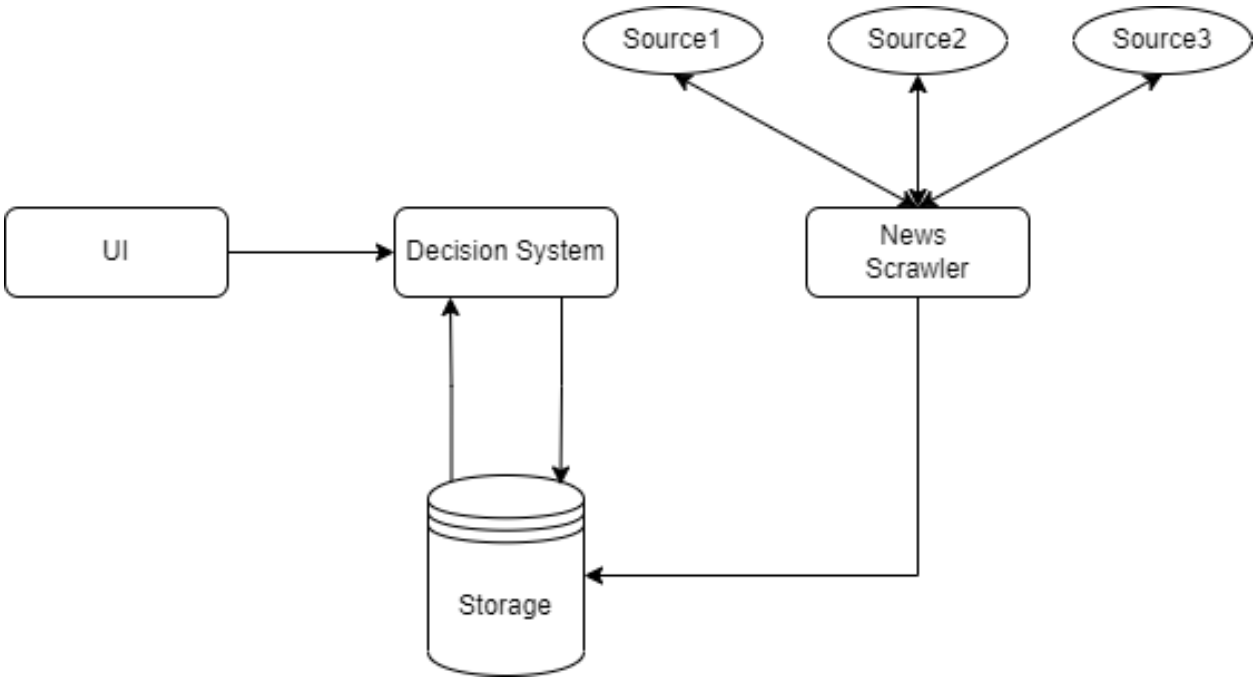


Рис. 1: Предполагаемая итоговая архитектура системы

На ней представлены следующие компоненты:

- **News Scrawler** — сервис, расположенный на платформе Microsoft Azure. Предназначение – сбор данных с четко заданных новостных источников и сохранение их в базе данных. Для каждого из источников потребуется программная доработка, т.к. в зависимости от сайта данные можно получать либо через API, либо анализируя содержимое веб-страницы.

- **Storage** — база данных MS SQL Server для хранения всех поступивших новостных событий и торговых рекомендаций. В данном сервисе возможно использование готовых библиотек для сбора новостей, подробнее о них в разделе 4.2.

- **Decision System** — система формирования торговых рекомендаций. Внутри неё с помощью NLP-библиотек будут выделяться ключевые признаки из текста и заголовка новости и на основе них выдавать торговую стратегию, понятную для пользователя.

- **UI** — пользовательский веб-интерфейс, позволяет получаь торговые рекомендации и работать с содержимым базы данных.

4.1. Стадии разработки

В ходе декомпозиции общей цели по реализации архитектуры были выделены следующие шаги:

- Реализация сервиса, работающего с несколькими источниками и в периодическом режиме пополняющего описанный в предыдущем разделе набор данных.
- Перенос существующего набора данных на схему базы данных, адаптация сервиса под неё.
- Реализация программы принятия торговых решений с использованием NLP-библиотек.
- Реализация пользовательского интерфейса.

4.2. Библиотеки для сбора новостей

В сервисе сбора новостей в качестве его части может быть использована готовая библиотека для сбора новостей с различных источников. Большинство из найденных библиотек написаны на языке Python и доступны для использования бесплатно, самые популярные из них описаны в этом разделе.

NewsCatcher

NewsCatcher[9] — одна из самых простых и в то же время популярных библиотек для сбора новостей. Авторы утверждают, что библиотека может собирать информацию с практически любого веб-сайта. Для работы с ней после установки достаточно создать объект с url-адресом интересующего сайта в конструкторе и в ответе вернется JSON-файл с новостными статьями, распознанными на сайте. Данная библиотека будет полезна при тестировании, однако, её главными недостатками является то, что в бесплатной версии доступны новости только за последний месяц и есть ограничение на количество запросов.

PyGoogleNews

PyGoogleNews[12] — библиотека-обертка над агрегатором новостей Google News. Может получать новости по поиску, популярности, теме или геолокации. Так же может находить связанные новости и выполнять сложные запросы с логическими операторами. Библиотека отлично подойдет для тестирования сценариев NLP в рамках будущей работы. Единственный недостаток – нельзя явно указать финансовый веб-сайт для сбора информации.

Feedparser

Feedparser[11] — библиотека для загрузки данных из RSS и Atom каналов новостей. Помимо сбора данных так же обладает рядом дополнительных функций, таких как очистка данных и нормализация данных. Недостаток аналогичный предыдущей библиотеке – работа только с новостями, опубликованными в RSS илии Atom форматах, чего может быть недостаточно для работы с финансовыми новостями и формирования торговых стратегий.

Newspaper3k

Newspaper3k[10] — Python библиотека для веб-скрейпинга новостных статей по URL-адресу. Может работать с несколькими языками и в многопоточном режиме, сразу очищая полученную информацию от лишних тегов и других результатов скрейпинга.

5. Результаты

Текущие результаты

На данный момент были достигнуты следующие результаты:

- Изучены работы, связанные с выделением релевантной информации из текста и предлагающие решения для формирования торговых стратегий.
- Собран и подготовлен набор данных для последующего анализа.
- Предложена архитектура системы для сбора новостей и формирования торговых стратегий.
- Рассмотрены существующие решения по сбору новостей из различных источников.

Дальнейшие планы

Общий план дальнейшей работы выглядит следующим образом:

- Реализация сервиса в автоматическом режиме пополняющего базу данных релевантных новостей.
- Исследование примеров событий в новостях, которые влияют на поведение базового инструмента.
- Извлечение всех признаков из новости и идентификация наиболее важных для поведения базового инструмента.
- Реализация системы торговых рекомендаций согласно архитектуре.
- Интеграция отобранных новостных признаков в систему.
- Оценка эффективности.

Список литературы

[1] Alex Micu Laurens Mast Viorel Milea. Financial News Analysis Using a Semantic Web Approach. — 2008.

[2] Chong Wang Lisa Kim Grace Bang Himani Singh Russell Kociuba Steven Pomerville Xiaomo Liu. Discovery News: A Generic Framework for Financial News Recommendation. — The Thirty-Second Annual Conference on Innovative Applications of Artificial Intelligence (IAAI-20), 2020.

[3] David Celjuska Dr. Maria Vargas-vera. Ontosophie: A Semi-Automatic System for Ontology. — In: International Conference on Natural Language Processing (ICON), 2004.

[4] HistData.com – Free Forex Historical Data. — URL: `http://www.histdata.com//` (online; accessed: 11.09.2021).

[5] InstaForex – Instant Forex Trading. — URL: `https://www.instaforex.com/` (online; accessed: 10.10.2021).

[6] Jethro Borsje Frederik Hogenboom Flavius Frasincar. Semi-automatic financial events discovery based on lexico-semantic patterns. — International Journal of Web Engineering and Technology, 2010.

[7] Jiahui Liu Peter Dolan E. Pedersen. Personalized news recommendation based on click behavior. — 2010.

[8] Mark L. Mitchell J.Harold Mulherin. The Impact of Public Information on the Stock Market. — The Journal of Finance, 1994.

[9] News Data: structured, relevant, real-time. — URL: `https://newscatcherapi.com/` (online; accessed: 11.12.2021).

[10] Newspaper3k: Article scraping & curation. — URL: `https://github.com/codelucas/newspaper` (online; accessed: 12.01.2021).

[11] feedparser. — URL: https://github.com/kurtmckee/feedparser (online; accessed: 12.01.2021).

[12] pygooglenews. — URL: https://github.com/kotartemiy/pygooglenews (online; accessed: 12.01.2021).

[13] Д.А. Григорьев А. В. Голубев Р. А. Шаламов. АДАПТИВНАЯ БАЗА ДАННЫХ СТЕММИНГОВЫХ СЛОВОФОРМ В ЗАДАЧЕ АВТОМАТИЧЕСКОГО ИЗВЛЕЧЕНИЯ ЗНАНИЙ ИЗ ТЕКСТОВЫХ ДОКУМЕНТОВ. — Всероссийская научная конференция «Традиции и Инновации», посвященная 193-й годовщине образования СПбГТИ(ТУ), 2021.